

Primjena PPO i DQN algoritama na upravljanje raskrsnicom sa željezničkom prugom


Andrej Vujić

RA130/2023

Okruženje

Okruženje predstavlja raskrsnicu koja je sačinjena od **8 traka za auta** i **2 trake za vozove**.

Okruženje je napravljeno pomoću **Python** biblioteke **pygame**.



Vozila se kreću po unaprijed definisanoj putanji. Svako vozilo se veže za određenu traku kada se ono kreira i doda u okruženje.

Konfiguracija za stvaranje novog vozila se definiše klasom **SpawnConfiguration**. Ova klasa sadrži informacije o traci kojoj vozilo pripada, incijalnom smjeru kretanja (relativni pomjeraj po **x** i **y** osama) i inicijalna rotacija (orijentacija).

Prilikom kreiranja novog vozila nasumično se bira neka od unaprijed definisanih konfiguracija. Automobili se stvaraju svaka **3** koraka okruženja sa vjerovatnoćom **75%**, dok se vozovi stvaraju svaka **64** koraka sa vjerovatnoćom **50%**.

Svaka konfiguracija sadrži i listu **Checkpoint** objekata. Oni definišu pozicije na mapi na kojima se stanje vozila mijenja.

Checkpoint se definiše za:

1. Ažuriranje stanja vozila (npr. prelazak iz stanja **APPROACHING_INTERSECTION** u stanje **IN_INTERSECTION**)
2. Ažuriranje smjera kretanja vozila i njegove orijentacije
3. Postavljanje flega za uklanjanje vozila iz okruženja (kada vozilo uspješno prođe kroz raskrsnicu)

Centralnu koordinaciju stvaranja i kretanja vozila obavlja **VehicleService** klasa. Ona obezbjeđuje da vozila moraju da stanu ukoliko je na traci na kojoj se nalaze upaljeno crveno svjetlo i da vozila formiraju kolonu prilikom čekanja bez pravljenja sudara.

Klasa **TrafficLightService** je zaduzena za upravljanje i vođenje evidencije o stanjima semaforima.

Agenti

Implementirana su četiri agenta čiji rezultati se porede:

1. **Random Agent** - njegovi potezi su u potpunosti nasumični, svaki korak okruženja bira nasumičnu fazu koju će da aktivira
2. **Basic Agent** – predstavlja klasičnu raskrsnicu u kojoj se periodično propušta saobraćaj na svakoj traci uz to da vozovi imaju prioritet i dobijaju dozvolu za prolaz kada se pojave
3. **DQN Agent**
4. **PPO Agent**

Svi agenti imaju **diskretan akcioni prostor** sačinjen od **13** mogućih akcija. Akcije predstavljaju dozvolu kretanja za jednu ili više kompatibilnih traka raskrsnice, uz izuzetak za poslednju akciju koja pali crveno svetlo za sve semafore. **Agenti biraju novu akciju svaki korak okruženja.**

```
TRAFFIC_LIGHT_PHASES = [  
    {0, 1}, # West -> East Left + Forward/Right  
    {2, 3}, # South -> North Left + Forward/Right  
    {4, 5}, # East -> West Left + Forward/Right  
    {6, 7}, # North -> South Left + Forward/Right  
  
    {1, 5}, # West -> East Forward/Right + East -> West Forward/Right  
    {3, 7}, # South -> North Forward/Right + North -> South Forward/Right  
  
    {1, 6}, # West -> East Forward/Right + North -> South Left  
    {3, 0}, # South -> North Forward/Right + West -> East Left  
    {5, 2}, # East -> West Forward/Right + South -> North Left  
    {7, 4}, # North -> South Forward/Right + East -> West Left  
  
    {8}, # Train East -> West  
    {9}, # Train South -> North  
]
```

Treniranje

PP0 i **DQN** agenti se treniraju ukupno **2,000,000** koraka okruženja.

Ulazno stanje sadrži **40** vrijednosti koje opisuju stanje okruženja na osnovu koga agenti biraju sledeću akciju. Sve vrijednosti u vektoru stanja su skalirane na opseg **[0, 1]** ili su diskretne vrijednosti iz skupa **{0, 1}**.

Stanje uključuje sledeće informacije:

1. Stanje semafora (**1** – upaljeno zeleno, **0** – upaljeno crveno), ukupno **10** vrijednosti
2. Broj vozila koja prilaze raskrsnici – za svaku traku po jedan broj iz opsega [**0**, **1**], ukupno **10** vrijednosti
3. Postojanje vozila u raskrsnici (**1** – ima bar jedno vozilo, **0** – nema vozila) – za svaku traku po jedan broj, ukupno **10** vrijednosti*
4. Broj vozila koja su prošla kroz raskrsnicu – za svaku traku po jedan broj iz opsega [**0**, **1**], ukupno **10** vrijednosti

* – Postojanje vozila u raskrsnici je uvedeno s ciljem da agent nauči da ne mijenja akciju dok god vozila prolaze kroz raskrsnicu s ciljem da se minimizuje broj sudara. Zbog toga je suštinski nebitan tačan broj vozila u raskrsnici za svaku traku. Dovoljno je znati da li ima ili nema vozila.

Pošto **VehicleService** klasa ima sve informacije o stanju okruženja ona je zadužena i za evaluaciju stanja okruženja odnosno akcija agenata.

Ispostavilo se da je kreiranje funkcije za evaluaciju stanja prilično komplikovano i da predstavlja ključni faktor za ishod treninga. Probane su mnoge verzije, a finalna verzija, između ostalog, uzima u obzir sledeće faktore:

1. Da li se desio sudar ili je agent “preživio” prethodno korak
2. Da se agent odlučuje za akcije koje narušavaju bezbednost učesnika u saobraćaju
3. Da se agent odlučuje za besmislene akcije
4. Broj vozila koja prilaze raskrsnici i čekaju
5. Broj vozila koja prolaze kroz raskrsnicu
6. Broj vozila koja su prošla kroz raskrsnicu

DQN Agent

DQN (Deep Q Network) je **off-policy** algoritam. Agent ne mora da uči samo iz iskustva kojeg je stekla njegova trenutna verzija. Trening petlja za ovog agenta je izgledala ovako:

1. Agent odabere akciju
2. Klasa **TrafficLightService** primijeni odabranu akciju
3. Klasa **VehicleService** simulira jedan korak okruženjaevaluira akciju
4. Agent pamti iskustvo, čuva ga u **ExperienceReplay** baferu
5. Agent uči iz skupljenog iskustva
6. Svakih **SYNC_INTERVAL** koraka se radi sinhronizacija parametara između mreža (**Policy Network** i **Target Network**)

PPO Agent

PPO (Proximal Policy Optimization) je **on-policy** algoritam. Agent može da uči samo iz iskustva kojeg je stekla njegova trenutna verzija. Trening petlja za ovog agenta je izgledala ovako:

1. Prva 3 koraka su ista kao kod **DQN**
2. Agent pamti iskustvo, čuva ga u **RolloutBuffer**
3. Kada skupi dovoljno iskustva (definisano parametrom **ROLLOUT_SIZE**) agent uči i **zaboravlja prethodno steknuto iskustvo**, učenje podrazumijeva ažuriranje parametara obe mreže (**ActorNetwork** i **CriticNetwork**)

Evaluacija

Agenti se evaluiraju na uzorku od **1,000** odigranih partija (svaka partija je ograničena na maksimalno **1,000** koraka). Da bi evaluacija bila poštena i svi agenti bili izloženi istim uslovima koristi se isti **seed** za generator pseudoslučajnih brojeva prilikom pokretanja evaluacije za svakog agenta.

Agenti se porede po sledećim metrikama:

1. Prosječna nagrada po igri, prosječna i maksimalna dužina igre, procent igara koje su završile sudarom
2. Broj vozila koja su prošla kroz raskrsnicu, prosječan i maksimalan broj aktivnih vozila u raskrsnici
3. Vrijeme čekanja vozila, prosječna i maksimalna dužina kolone, procenat vremena u kojem je postojala kolona na određenoj traci raskrsnice
4. Broj promjena stanja semafora

Zaključak

Random Agent je očekivano najlošiji. Ima **collision rate** od **100%**, pa se igre završavaju veoma brzo, u prosjeku traju oko **100** koraka. Zbog toga neke metrike čekanja izgledaju varljivo dobro, posebno čekanje auta od oko **4** koraka, jer agent ne preživi dovoljno dugo da napravi velike kolone. Protok je ubjedljivo najlošiji jer u prosjeku prolazi oko **15** vozila po igri i gotovo nijedan voz, što je direktna posljedica kratkog trajanja igara i velikog broja sudara.

Zaključak

Basic Agent je najstabilniji po pitanju bezbjednosti. Ima idealan **collision rate** od **0%** i maksimalnu moguću prosječnu dužinu igre od **1000** koraka. Takođe ima vrlo dobar protok od oko **230** vozila po igri. Glavna mana mu je čekanje. Auta čekaju u prosjeku oko **63** koraka, a vozovi oko **15**, što ga čini najlošijim među agentima koji postižu značajne rezultate.

Zaključak

DQN Agent je naučio korisno ponašanje, ali nije dovoljno stabilan. Ima solidan prosječan broj koraka – oko **820**, a i prosječna nagrada mu je pozitivna. **Collision rate** od oko **37%** je prilično visok. Najbolja strana mu je čekanje: auta čekaju samo oko **15** koraka, a vozovi praktično ne čekaju. Međutim, taj agresivniji stil dolazi uz veliki broj promjena faza i dosta sudara. DQN dobro optimizuje čekanje, ali nedovoljno poštuje sigurnost.

Zaključak

PP0 Agent izgleda kao najbolji balans. Ima nizak **collision rate** od oko **6%**, prosječnu dužinu igre od oko **970** koraka, najbolji prosječan reward i najbolji prosječan protok sa oko **240** vozila po igri. Takođe propušta najviše auta i vozova u prosjeku. Vrijeme čekanja auta je veće nego kod **DQN**-a, oko **24** koraka, ali je i dalje mnogo bolje od **Basic Agent**a. Čekanje vozova je vrlo nisko, u prosjeku manje od jednog koraka. Ukupno, **PP0** je najbolji agent u ovoj evaluaciji jer postiže visok protok uz relativno mali broj sudara.